

1. Giriş

1.1 Projenin Amacı

İnternet üzerinde yer alan haber içeriklerinin hızla artması, kullanıcıların doğru ve güvenilir bilgiye erişimini zorlaştırmaktadır. Geleneksel anahtar kelime tabanlı arama sistemleri çoğu zaman yalnızca metinsel benzerliği dikkate almakta, sayfaların bağlantısal önemini ve güvenilirliğini hesaba katmamaktadır. Bu nedenle modern arama sistemlerinde yalnızca içerik analizi değil, aynı zamanda web yapısının da incelenmesi gerekmektedir. Bu proje kapsamında Türkçe haber siteleri üzerinde çalışan hibrit bir web mining tabanlı haber arama sistemi geliştirilmiştir. Sistem, kullanıcı sorgularına daha alakalı sonuçlar döndürebilmek amacıyla içerik tabanlı bilgi erişim yöntemleri ile web structure mining yöntemlerini birlikte kullanmaktadır.

Projede: BM25, PageRank, HITS algoritmaları uygulanmış ve aynı veri kümesi üzerinde karşılaştırılmıştır. Böylece yalnızca içerik benzerliğini dikkate alan yöntemler ile bağlantısal analiz kullanan yöntemlerin performans farkları incelenmiştir.

2. Veri Seti ve Veri Toplama Süreci

2.1 Common Crawl Veri Seti

Projede veri kaynağı olarak Common Crawl kullanılmıştır. Common Crawl, internet üzerindeki web sayfalarını WARC formatında arşivleyen büyük ölçekli açık veri kaynağıdır. WARC dosyaları içerisinde: URL bilgileri, HTML içerikleri, HTTP response kayıtları, metadata bulunmaktadır. Projede bu dosyalar ArchiveIterator kullanılarak işlenmiştir.

2.2 Haber Sitelerinin Filtrelenmesi

Common Crawl yalnızca haber sitelerini içermediği için veri kümesi filtrelenmiştir. Basın İlan Kurumu gazete listesi kullanılarak haber domainleri manuel biçimde belirlenmiş ve yalnızca bu sitelere ait sayfalar veri kümesine dahil edilmiştir. Bu sayede: alakasız web sayfaları elenmiş, veri seti haber odaklı hale getirilmiş, graph algoritmaları için daha anlamlı bağlantı yapısı oluşturulmuştur.

2.3 Veri Toplama İşlemleri

Veri toplama işlemleri download.py dosyasında gerçekleştirilmiştir. Sistem Common Crawl WARC dosyalarını okuyarak haber domainleri ile eşleşen sayfaların: URL, başlık, ham HTML içeriklerini PostgreSQL veritabanındaki pages tablosuna kaydetmektedir.

3. Veri Ön İşleme (Preprocessing)

Ham HTML içerikler doğrudan kullanılmamıştır. preprocessing.py ve text_preprocessing.py dosyaları kullanılarak: HTML tagleri temizlenmiş, görünmeyen içerikler kaldırılmış, haber metni çıkarılmış, hyperlinkler elde edilmiştir. Ardından metinler: küçük harfe çevrilmiş, tokenize edilmiş, stopword removal uygulanmıştır. Temizlenmiş metinler, token listeleri ve hyperlink bilgileri pages_cleaned tablosunda saklanmaktadır.

4. Veritabanı Yapısı

Projenin veritabanı yapısı aşağıda verilen tabloda özetlenmiştir.

Tablo 1 Sistem İçerisinde Kullanılan Veritabanı Tabloları

Tablo	İçerik	Kısa Açıklama
pages	url, title, html	Common Crawl üzerinden elde edilen ham HTML haber verilerini tutmaktadır.
pages_cleaned	text, tokens, links	Temizlenmiş haber metinleri, tokenize edilmiş kelimeler ve hyperlink bilgilerini içermektedir. Arama sistemi için temel veri kaynağıdır.
inverted_index	term, doc_id, frequency	Her kelime için ilgili doküman listesini ve kelime frekansını saklamaktadır. Hızlı bilgi erişimi ve BM25 skor hesaplamasında kullanılmaktadır.
pagerank	doc_id, score	Dokümanların hyperlink graph yapısına göre hesaplanan PageRank skorlarını tutmaktadır.
hits	doc_id, hub_score, authority_score	HITS algoritmasına ait hub ve authority skorlarını saklamaktadır. Güvenilir ve merkezi kaynakların belirlenmesinde kullanılmaktadır.

Tablo 1’de görüldüğü üzere sistem içerisinde hem içerik tabanlı retrieval işlemleri hem de graph tabanlı analizler için ayrı veri yapıları kullanılmaktadır. Özellikle inverted index yapısı hızlı sorgulama işlemlerini desteklerken, PageRank ve HITS tabloları bağlantısal önem analizlerinde kullanılmaktadır.

5. Algoritmalar

5.1 BM25 Algoritması

BM25, kullanıcı sorgusuyla en alakalı dokümanları bulmak için kullanılan klasik bir information retrieval algoritmasıdır. Algoritma: term frequency, inverse document frequency (IDF), document length bilgilerini birlikte kullanmaktadır.

Kelimenin dokümanda sık geçmesi skoru artırırken, yaygın kelimeler daha düşük ağırlık almaktadır. Ayrıca document length normalization sayesinde uzun dokümanların avantaj kazanması engellenmektedir.

5.2 PageRank Algoritması

PageRank algoritması hyperlink yapısını analiz ederek sayfa önemini hesaplamaktadır. Projede haber sayfaları node, hyperlinkler ise directed edge olarak modellenmiştir.

Algoritma özellikle: merkezi, güvenilir, çok referans verilen haber kaynaklarını öne çıkarmaktadır.

5.3 HITS Algoritması

HITS algoritması hub ve authority olmak üzere iki farklı skor üretmektedir.

Authority score güvenilir bilgi kaynaklarını, Hub score ise kaliteli kaynaklara bağlantı veren sayfaları temsil etmektedir.

6. Hibrit Sıralama Sistemi

Tablo 2 Hibrit Sıralama Yaklaşımları

Yöntem	Açıklama
BM25	Yalnızca içerik tabanlı
BM25 + PageRank	İçerik + bağlantısal önem
BM25 + PageRank + HITS	Gelişmiş hibrit sistem


Tablo 2’de görüldüğü üzere sistem farklı ağırlık kombinasyonları ile içerik benzerliği ve bağlantısal güvenilirlik bilgisini birlikte değerlendirmektedir. Böylece yalnızca keyword matching değil, aynı zamanda sayfa otoritesi ve hyperlink yapısı da sıralama sürecine dahil edilmektedir.

7. Sistem Mimarisi

Sistem mimarisi veri toplama, preprocessing, indexleme ve online search olmak üzere dört temel aşamadan oluşmaktadır. İlk aşamada Common Crawl WARC dosyaları içerisinden haber sayfaları çekilmekte ve PostgreSQL veritabanına kaydedilmektedir. Daha sonra preprocessing aşamasında HTML temizleme, tokenization, stopword removal ve hyperlink extraction işlemleri uygulanmaktadır.

Temizlenen veriler üzerinden inverted index yapısı oluşturulmakta, ardından hyperlink graphkullanılarak PageRank ve HITS skorları hesaplanmaktadır. Online search aşamasında Flask REST API kullanıcı sorgularını işleyerek BM25, PageRank ve HITS skorlarını hibrit biçimde birleştirmekte ve sonuçları Next.js tabanlı frontend arayüzüne göndermektedir.

Sistemin genel veri akışı ve bileşen yapısı Şekil 1’de gösterilmektedir.



Şekil 1 Sistem Mimarisi ve Veri İşleme Pipeline’ı

8. Kullanılan Teknolojiler

Tablo 3 Projede Kullanılan Teknolojiler

Teknoloji	Kullanım
Python	Backend ve preprocessing
Flask	REST API
PostgreSQL	Veritabanı
Next.js	Frontend
BeautifulSoup	HTML parsing
NetworkX	Graph işlemleri
psycopg2	PostgreSQL bağlantısı

9. GUI ve Kullanıcı Arayüzü

Projede responsive ve kullanıcı dostu bir web arayüzü geliştirilmiştir. Arayüz Next.js kullanılarak hazırlanmış ve Flask tabanlı backend API ile entegre edilmiştir. Sistem temel olarak ana arama sayfası ve web mining analiz sayfasından oluşmaktadır.

9.1 Dataset Manager

Ana sayfa üzerinden kullanıcı haber veri kümesi üzerinde arama yapabilmekte ve sonuçları liste halinde görüntüleyebilmektedir. Pagination yapısı sayesinde farklı sonuç sayfaları arasında geçiş yapılabilmektedir. Bu bölüm veri keşfi ve örnek kayıt görüntüleme işlevini sağlamaktadır.

9.2 Algorithm Runner & Comparator


/web-mining sayfasında kullanıcı BM25, PageRank ve HITS algoritmalarına ait: alpha, beta, gamma ağırlık değerlerini değiştirebilmektedir. Farklı parametre kombinasyonları kullanılarak algoritmaların sıralama üzerindeki etkisi karşılaştırılabilmektedir.

9.3 Results & Analysis


Results & Analysis bölümü ana sayfadaki arama sonuç ekranı ile sağlanmaktadır. Kullanıcı bir sorgu gönderdiğinde backend tarafında ilgili haberler BM25 ve hibrit sıralama mantığına göre hesaplanmakta, ardından sonuçlar relevance skorlarına göre sıralı biçimde listelenmektedir.

Sonuç ekranında haber başlıkları, kaynak domain bilgisi, eşleşme skoru ve sayfalama bilgisi gösterilmektedir. Kullanıcı top-ranked haberleri inceleyebilmekte, her sonucun kaynağına gidebilmekte ve farklı sayfalardaki sonuçları karşılaştırılabilmektedir. Bu yapı, ödevde istenen ranked result display ve output example gereksinimlerini karşılamaktadır.

Genel olarak geliştirilen GUI; veri üzerinde sorgulama, algoritma parametrelerini değiştirme ve sıralanmış sonuçları analiz etme işlevlerini sağlamaktadır. Eksik kalan tek nokta, Dataset Manager ekranında ayrıntılı veri istatistiklerinin ayrı kartlar veya grafikler halinde gösterilmemesidir.



Şekil 2 BM25, PageRank ve HITS Parametre Karşılaştırma Arayüzü



Şekil 3 Ranked Search Results ve Relevance Analysis Ekranı

10. Performans Değerlendirmesi

Sistem performansını değerlendirmek amacıyla doğal afet, ekonomi ve spor kategorilerinden farklı sorgular seçilmiştir. Her sorgu için döndürülen ilk 10 sonuç manuel relevance labeling yöntemi ile incelenmiş ve ilgili olduğu düşünülen dokümanlar değerlendirme veri kümesine dahil edilmiştir.

Evaluation sürecinde: Accuracy, Precision, Recall, F1-Score metrikleri kullanılmıştır.

Sonuçlar sistemin keyword-based retrieval konusunda başarılı olduğunu göstermektedir. Özellikle “deprem oldu mu” sorgusunda sistem oldukça yüksek başarı elde etmiştir. Ancak lokasyon bazlı ve semantic intent gerektiren sorgularda relevance başarısında düşüş gözlemlenmiştir.

“İzmir’de deprem oldu mu” sorgusunda sistem query içerisindeki “deprem” kelimesini başarılı biçimde eşleştirmiş ancak lokasyon bilgisini tam olarak anlayamamıştır. Benzer şekilde “Süper Lig puan durumu” sorgusunda spor ile ilişkili ancak query intent ile doğrudan bağlantılı olmayan birçok sonuç üst sıralarda listelenmiştir.

Ekonomi sorgularında ise sistem genel olarak başarılı performans göstermiştir. Bununla birlikte bazı sonuçlarda semantic context understanding eksiklikleri gözlemlenmiştir.

Tablo 4. Query Bazlı Evaluation Metric Sonuçları

Query	Accuracy	Precision	Recall	F1-Score
deprem oldu mu	1.00	1.00	1.00	1.00
izmirde deprem oldu mu	0.30	1.00	0.30	0.46
asgari ücret ne kadar oldu	0.80	1.00	0.80	0.89
süperlig puan durumu	0.10	1.00	0.10	0.18

11. Algoritmaların Karşılaştırılması ve Trade-Off Analizi

Projede BM25, PageRank ve HITS algoritmaları hibrit biçimde kullanılmıştır. Yapılan parametrik deneyler algoritmaların farklı güçlü ve zayıf yönleri sahip olduğunu göstermiştir.


BM25-only konfigürasyonunda sistem keyword matching açısından oldukça başarılı sonuçlar üretmiştir. Özellikle “deprem oldu mu” sorgusunda ilk 10 sonucun tamamı ilgili haberlerden oluşmuştur. Bu durum BM25 algoritmasının lexical relevance konusunda güçlü performans gösterdiğini ortaya koymaktadır.

Balanced Hybrid yaklaşımında ($\alpha = 0.6$, $\beta = 0.3$, $\gamma = 0.1$) relevance korunurken authority etkisi de sıralamaya dahil edilmiştir. Bu yapı hem keyword relevance’ı hem de bağlantısal güvenilirliği birlikte değerlendirdiği için daha dengeli sonuçlar üretmiştir.

Graph-heavy konfigürasyonunda ($\alpha = 0.3$, $\beta = 0.5$, $\gamma = 0.2$) ise PageRank ve HITS skorları aşırı baskın hale gelmiştir. Bu nedenle query ile doğrudan ilişkili olmayan haberler üst sıralarda listelenmiştir. Özellikle: siyaset, magazin, genel gündem haberlerinin relevance’ın önüne geçtiği gözlemlenmiştir.

Sonuç olarak:

- BM25 keyword relevance açısından güçlü performans göstermektedir.
- PageRank ve HITS güvenilir kaynakların öne çıkmasına katkı sağlamaktadır.
- En dengeli sonuçlar Balanced Hybrid yaklaşımında elde edilmiştir.
- Sistem semantic search ve query intent understanding konularında geliştirilmeye açıktır.



Şekil 4 Sorgu Bazlı Retrieval Performance Metriklerinin Karşılaştırılması

12. Sonuç

Bu projede Common Crawl veri kümesi kullanılarak Türkçe haber içerikleri üzerinde çalışan hibrit bir haber arama sistemi geliştirilmiştir. Sistem içerisinde BM25, PageRank ve HITS algoritmaları birlikte kullanılmış ve farklı ağırlık kombinasyonları karşılaştırılmıştır.

Sonuçlar BM25 algoritmasının keyword relevance açısından başarılı olduğunu, PageRank ve HITS algoritmalarının ise bağlantısal güvenilirlik bilgisini sisteme katkı sağladığını göstermiştir. Özellikle balanced hybrid yaklaşımı en dengeli sonuçları üretmiştir.

Bununla birlikte sistem semantic search ve query intent understanding konularında geliştirilmeye açıktır. Future work kapsamında transformer tabanlı embedding modelleri, dense retrieval yöntemleri ve named entity recognition teknikleri kullanılarak semantic relevance kalitesinin artırılması hedeflenmektedir.

13. Referanslar

- [1] Robertson, S., & Zaragoza, H. (2009). *The probabilistic relevance framework: BM25 and beyond* (Vol. 4). Now Publishers Inc.
- [2] Brin, S., & Page, L. (1998). The anatomy of a large-scale hypertextual web search engine. *Computer networks and ISDN systems*, 30(1-7), 107-117.
- [3] Kleinberg, J. M. (1999). Authoritative sources in a hyperlinked environment. *Journal of the ACM (JACM)*, 46(5), 604-632.
- [4] Common Crawl Foundation. <https://commoncrawl.org/>
- [5] BeautifulSoup Documentation. <https://www.crummy.com/software/BeautifulSoup/>
- [6] NetworkX Documentation. <https://networkx.org/>
- [7] Flask Documentation. <https://flask.palletsprojects.com/>
- [8] Next.js Documentation. <https://nextjs.org/>
- [9] PostgreSQL Documentation. <https://www.postgresql.org/>
- [10] Basın İlan Kurumu Gazeteler Listesi. <https://www.ilan.gov.tr/>